# Igranje zmijice pomoću veštačke inteligencije Danijel Radaković – Fakultet tehničkih nauka

Uvod

### Pravila igre:

- zmijica se proizvoljno kreće po tabli
- kad pojede hranu zmijica i rezultat se uvećavaju za 1
- kraj igre je ukoliko se zmijica sudari sa zidom ili svojim telom
- cilj je skupit što je moguće više poena **Cilj** istraživanja je napraviti agente koji će

osvojiti što veći broj poena.

# Slika 1: Zmijica

### Istraživačka pitanja

- Koji algoritam donosi najbolje rezultate?
- Da li je igra rešena?

### Rezultati

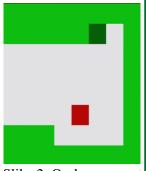
- A\*: zmijica brzo raste na početku, a kada zmijica naraste nastaje problem zarobljavanja zmijice oko svog tela.
- MCTS: 140 ms je dovoljno da se simuliraju potezi na malim tabla pa se agent solidno ponaša. Za veće table to nije slučaj jer nema dovoljno vremena za simuliranje.
- **Q-learning**: na tabli 5x5, 100.000 epizoda je dostignuto 9 poena, a na 8x8 posle 300.00 je dostignuto 3 poena.
- Monte Carlo Q-learning: posle samo 120 epizoda dostigao je 2 poena što običan Q-learning je mogao tek posle 800 epizoda.

Agent	Poeni
Random	1
Zigzag	24
Smart	27
Oroborus	61
MC	12
Q	3
MCQ	12

Tabela 1: Rezultati

# Algoritmi

- A\* koristi cenu i heuristiku: Zigzag, Smart i Oroborus agenti.
- Monte Carlo Tree Search (MCTS) koristi simulacije i na osnovu njih bira akcije: MC agent.
- **Q-learning** isprobava akcije i bira onu koja je najbolja: Q agent.
- Monte Carlo Q-learning kombinacija Q-learning-a i MCTS: MCQ agent.



Slika 2: Oroborus agent

## Diskusija

- Kuda zmijica da se kreće kada ne može direktno da dođe do hrane?
- Kako sprečiti zmijicu da se zarobi oko svog tela?

### Zakliučak

- Igra može da se reši ako je barem jedna dimenzija table paran broj.
- A\* se pokazao kao najbolji, ali se mora paziti prilikom implementacije da bi se izvršavao u realnom vremenu.
- MCTS radi dobro za male table, ali ima poteškoća na većim tablama.
- Q-learning sporo konvergira i zauzima veliku količinu memorije.
- MC Q-learning se dobro pokazao za skaliranje Q-learning-a.